

¿Cómo influyen el tiempo de uso diario, la frecuencia de revisión, la edad y el sexo con el uso problemático de redes sociales (PSMU)?

Nassir Cardenas^{1,*} and Andrea Blanco Rodríguez²

¹ Pregrado Ciencia de Datos Universidad Externado, Bogotá - Colombia

² Pregrado Ciencia de Datos Universidad Externado, Bogotá - Colombia

RESUMEN

Este estudio analiza la relación de comportamientos y variables demográficas entre el uso problemático de redes sociales, empleando un enfoque bayesiano basado en árboles de decisión (BART). Se exploró la importancia relativa de variables predictoras como sexo, edad, tiempo diario de uso y frecuencia de revisión de redes y se analizaron sus efectos mediante gráficos de dependencia parcial (PDP) e importancia de variable.

Palabras Clave: Redes sociales, psmu, BART

Entrega: 15 de mayo de 2025.

ABSTRACT

This study analyzes the relationship between behaviors and demographic variables in problematic social media use, employing a Bayesian Additive Regression Trees (BART) approach. The relative importance of predictor variables gender, age, daily usage time, and frequency of checking social media was explored, and their effects were analyzed using partial dependence plots (PDP) and variable-importance metrics.

Keywords: Social media, psmu, BART

1. Planteamiento Teorico

El enfoque del problema se centra en la compleja relación entre el uso de redes sociales (SNS) y cómo los jóvenes adultos perciben su satisfacción con la vida. Aunque las SNS ofrecen oportunidades para conectarse, informarse y formar comunidades, también despiertan preocupaciones sobre su posible efecto negativo en el bienestar psicológico y social.

Un fenómeno clave es el uso problemático de redes sociales (PSMU), que la revisión sistemática de Hylkilä et al. (2024) vincula, en la mayoría de los casos, con un menor bienestar social. Esto incluye asociaciones con relaciones sociales y parasociales en SNS, así como con la ansiedad en redes sociales. Sin embargo, los resultados fueron mixtos, lo que significa que los diferentes estudios incluidos en la revisión obtuvieron hallazgos inconsistentes o contradictorios, lo que resalta lo complicada que es esta relación. Una de las limitaciones más importantes que se identificó es la variedad de definiciones de PSMU y bienestar social

que se utilizan en los estudios, lo que dificulta comparar los hallazgos. La diversidad de escalas para medir PSMU, como la Escala de Adicción a Facebook de Bergen (BFAS) y la Escala de Adicción a las Redes Sociales de Bergen (BSMAS), junto con las múltiples interpretaciones del bienestar social, contribuyen a esta heterogeneidad.

Otro punto clave es la diferencia entre el uso activo y pasivo de las redes sociales. El uso activo implica interactuar directamente y contribuir con contenido, mientras que el uso pasivo se enfoca en consumir el contenido de otros. Ozimek et al. (2023) sugieren que estas modalidades pueden tener efectos diferentes en el bienestar. Por ejemplo, el uso pasivo de Facebook se ha asociado con una disminución del bienestar afectivo. Comprender la proporción de actividades activas y pasivas es vital para discernir el impacto de las SNS en la satisfacción con la vida.

El miedo a perderse algo, conocido como FoMO (Fear of Missing Out), se ha convertido en un factor psicológico importante. Se refiere a la ansiedad que sentimos al pensar

que otros están disfrutando de experiencias gratificantes de las que nosotros estamos ausentes, lo que nos lleva a buscar constantemente conexión a través de las redes sociales. Un metaanálisis realizado por Akbari et al. (2023) resalta la fuerte relación entre el FoMO y el uso de Internet, especialmente en redes sociales. Este miedo puede llevar a un uso más frecuente y compulsivo de estas plataformas, lo que podría tener un impacto negativo en nuestro bienestar y satisfacción con la vida.

La investigación previa ha mostrado resultados variados sobre cómo el uso de redes sociales se relaciona con el bienestar. Algunos estudios sugieren que puede haber efectos positivos en ciertas circunstancias, mientras que otros destacan los efectos negativos. Esta diversidad resalta la necesidad de realizar investigaciones más profundas que tomen en cuenta la complejidad del uso, la variedad de experiencias y la influencia de factores psicológicos como el FoMO. Es crucial analizar por separado los aspectos positivos y negativos del bienestar para entender mejor cómo se relacionan con el uso problemático de redes sociales.

1.1 El problema

En los últimos años, el uso de las redes sociales ha mostrado un crecimiento rápido, volviéndose algo normal en la vida de los jóvenes. Según Statista (2020), el número de usuarios de redes sociales en el mundo alcanzó aproximadamente 2.460 millones en 2017 y se estimó que para finales de 2021 habría alrededor de 3.090 millones. Este incremento destaca la expansión de estas plataformas en la sociedad y su importancia en la vida de las nuevas generaciones (Casale & Banchi, 2020).

El incremento en el uso de redes sociales ha generado preocupaciones y dudas sobre sus consecuencias en la vida de los jóvenes, ya que distintos estudios han identificado que el uso intensivo de las plataformas está implicado en resultados negativos para la salud mental, como síntomas de trastornos psiquiátricos y comportamientos adictivos. Por ejemplo se halló una correlación positiva significativa entre síntomas de depresión el uso de redes sociales (Andreassen et al., 2016) y de igual manera se halló una relación negativa entre la autoestima y adicción a Facebook. La “intrusión de Facebook” es un ejemplo de cómo el uso constante y excesivo de una plataforma puede interrumpir las actividades diarias y afectar el bienestar general de los usuarios (Casale & Banchi, 2020).

El crecimiento de redes sociales como TikTok también ha sido significativo para los jóvenes, ya que se ha observado que plataformas como esta ofrecen ambientes altamente inmersivos diseñados para captar la atención de los usuarios durante largos periodos (Montag, Yang,

& Elhai, 2021). En China, el 81.68% de los usuarios de TikTok tienen menos de 35 años, mientras que en Estados Unidos el 32.5% de los usuarios tienen 19 años o menos. Esto muestra que los adolescentes y jóvenes adultos son un grupo importante dentro de estas plataformas, lo que alerta sobre la necesidad de analizar su impacto en su bienestar.

Durante la pandemia de COVID-19, el uso de redes sociales se incrementó debido al distanciamiento social. Esto provocó que las plataformas se convirtieran más que en una necesidad, en un medio para la socialización, frecuentado principalmente por los adolescentes. Investigaciones han mostrado que el uso excesivo también ha contribuido al aumento de problemas como la “depresión de Facebook”, el “miedo a perderse algo” (FoMO) y la “orientación a la comparación social” (SCO), afectando negativamente el bienestar subjetivo de los jóvenes (Duradoni, Innocenti, & Guazzini, 2020).

Por el contexto anterior, es importante estudiar el impacto de las redes sociales en la vida de los jóvenes para conocer los riesgos generados por su uso excesivo, ya que estas plataformas han cambiado la forma en que los jóvenes socializan y construyen su identidad. Por lo tanto, es necesario investigar a fondo cómo afectan su salud mental, bienestar emocional y calidad de vida en general.

El enfoque bayesiano es importante para este estudio porque nos permite ajustar los pesos de las variables a medida que obtenemos nueva evidencia, lo que resulta en estimaciones más sólidas y flexibles. Al combinar información teórica con datos empíricos recientes, podemos crear un modelo que no solo detecte correlaciones, sino que también nos ayude a entender cómo y en qué medida se relacionan los patrones de comportamiento en el uso de redes sociales con la presencia de adicción conductual y sus posibles consecuencias en la vida cotidiana de los jóvenes.

Por el impacto que estas plataformas tienen en la vida diaria de las nuevas generaciones, es adecuado usar métodos analíticos que nos ayuden a evaluar con mayor precisión los efectos que generan. Esta metodología puede proporcionar resultados confiables y útiles para diseñar estrategias que reduzcan los riesgos y promuevan un uso saludable de las redes sociales entre los jóvenes.

1.2 Objetivos

1.3 Objetivo general

- Analizar cómo el sexo, la edad, el tiempo de uso y la frecuencia de revisión de redes sociales se asocian con la adicción conductual en jóvenes de 14 a 22 años.

1.4 Objetivos específicos

- Evaluar si el tiempo invertido en redes sociales al día se asocia con el BSMAS.
- Determinar si la frecuencia con la que los jóvenes revisan sus redes sociales predice tener adicción a las redes sociales.
- Explorar cómo influye la variable sexo en la relación entre el uso problemático de redes sociales.

2. Marco teórico

La adicción a redes sociales se define como un conjunto de acciones compulsivas y desadaptativas en las plataformas, donde existe una necesidad repetitiva o urgente de conectarse, presentándose una pérdida de control sobre el tiempo de uso y permanencia a pesar de las consecuencias negativas en el ámbito personal, social y académico (Andreassen et al., 2014; Griffiths, 2005). A diferencia de otras formas de adicción, esta entra dentro de las adicciones comportamentales en las que no hay intervención de sustancias, pero sí se observan síntomas similares como tolerancia, abstinencia y deterioro funcional (American Psychiatric Association, 2013).

La literatura existente aborda la compleja relación entre las redes sociales y el bienestar. Investigaciones recientes destacan cómo el uso problemático de redes sociales (PSMU) se vincula con una disminución en el bienestar social y emocional (Hylkilä et al., 2024). El PSMU ha sido ligado a consecuencias como reducción de la calidad del sueño, bienestar deteriorado y problemas interpersonales (Zarate et al., 2022). Asimismo, el fenómeno del *FoMO* se ha identificado como un factor clave que impulsa el uso compulsivo de estas plataformas (Akbari et al., 2023).

Por otra parte, la distinción entre uso activo y pasivo de SNS ha permitido evidenciar efectos diferenciados: mientras el uso activo puede favorecer la construcción de redes de apoyo, el uso pasivo se asocia frecuentemente con sentimientos de aislamiento y ansiedad (Ozimek et al., 2023).

Diversos estudios han evidenciado que un uso frecuente y prolongado de redes sociales está fuertemente asociado con la aparición de comportamientos adictivos y efectos negativos en la salud mental. Bleas (2015) identifica que este tipo de uso incrementa el riesgo de padecer trastornos como la “depresión por Facebook”, el miedo a perderse algo (FoMo) y la orientación hacia la comparación social (SCO). Según Andreassen et al. (2014), la adicción conductual a redes sociales se manifiesta como una preocupación excesiva por estas plataformas y motivaciones incontrolables para acceder a ellas, con una inversión de

tiempo que interfiere en otras áreas importantes de la vida cotidiana. Esto concuerda con los hallazgos de Griffiths (2005) y Buote et al. (2009), quienes también mencionan el deterioro funcional como característica central de la adicción comportamental.

La American Academy of Pediatrics (2011) ya había advertido sobre los riesgos del uso intensivo de redes sociales en adolescentes, destacando la aparición de síntomas depresivos por el tiempo excesivo en plataformas como Facebook. Datos recientes de We Are Social (2022) revelan que, en promedio, las personas dedican 2 h 27 min diarios a estas plataformas, lo cual apoya la necesidad de estudiar cómo esta exposición prolongada incide en la salud mental (Vannucci, 2019).

La investigación muestra que el uso problemático de redes sociales es más común durante la adolescencia temprana. En particular, entre las niñas, los efectos negativos en la salud mental, como la ansiedad, se observan con más frecuencia en aquellas que están en los últimos años de la adolescencia (aproximadamente entre los 16 y 18 años) que en las más jóvenes. La mayoría de los estudios se han centrado en jóvenes universitarios de entre 19 y 25 años, lo que limita la generalización de los hallazgos a toda la población usuaria de redes sociales. Por esta razón, los autores sugieren que se realicen más investigaciones con otros grupos de edad.

Cheng, Lau, Chan y Luk (2021) señalan que la adicción a las redes sociales es más común en poblaciones adolescentes (35%) en comparación con estudiantes universitarios (23%) y adultos de la comunidad (19%). La mayoría de los estudios se enfocan en Facebook, y la escala más utilizada para medir esta adicción, la BFAS, fue adaptada a la BSMAS para abarcar distintas plataformas sociales.

La Bergen Social Media Addiction Scale (BSMAS) es una adaptación de la original BFAS enfocada en Facebook, y es una de las herramientas más utilizadas para evaluar la adicción conductual a redes sociales en distintos contextos culturales y etarios. Esta escala se basa en seis componentes de la adicción: prominencia, modificación del estado de ánimo, tolerancia, abstinencia, conflicto y recaída (Andreassen et al., 2014; Griffiths, 2005). Su uso generalizado permite comparar resultados en distintos países y aportar evidencia empírica directa sobre los efectos del uso problemático de redes sociales.

Dentro de los diferentes hallazgos del uso problemático de redes sociales se menciona la “intrusión de Facebook”, introducida por Elphinston y Noller (2011), donde este término se define como un “apego excesivo a Facebook, que interfiere con las actividades diarias y con el funcionamiento de las relaciones” (p. 631). Esta definición se

basa en los componentes de la adicción conductual propuestos por Brown (1997).

3. Presentación de gráficas referentes al problema de investigación

Distribución de BSMAS_CUTOFF




Fig. 1. Gráfica de adicción a redes sociales, se utiliza una codificación binaria donde 0 representa no adicción y 1 adicción. La clasificación se basa en un umbral establecido para la Escala de Bergen de Adicción a Redes Sociales (BSMAS), considerándose adicción cuando el puntaje total es ≥ 19 . (Andreassen et al., 2014).

3.1 Análisis univariado de las variables predictoras

La elección de cada una de estas variables se hizo de acuerdo a la literatura que se consultó y que mostraban relación a PSMU.

- **Time spent on social media (Tiempo invertido en redes sociales):** Indica el número de horas que un individuo pasa en las redes sociales. Las categorías varían entre 0 (0-2 horas), 1 (2-4 horas), 2 (4-6 horas), 3 (3-8 horas), 4 (8-10 horas) y 5 (10 horas o más). Su inclusión se fundamenta en la evidencia reportada por Hilty et al. (2023).




Fig. 2. Distribución variable Time spent on social media.

La siguiente distribución resume las horas diarias que los usuarios dedican a redes sociales:

- **38%** de los usuarios emplean entre 2 y 4 horas al día.
- **27%** dedican de 4 a 6 horas.
- Solo **3%** supera las 8 horas diarias, siendo el grupo menos representativo.

Este patrón refleja que, aunque el uso moderado (2-6 horas) es mayoritario, existe un pequeño porcentaje con hábitos de alto riesgo (>8 horas).

• Age (Edad)




Fig. 3. Distribución variable Age .

El rango etario de la población estudiada abarca desde los **14 hasta los 22 años**. La distribución presenta las siguientes características:

- **Edad predominante:** 18 años (mayor frecuencia en la muestra)
- **Grupos menos representados:** jóvenes de 21 y 22 años
- **Rango intermedio:** 14-17 años y 19-20 años con frecuencias moderadas

Esta concentración en adolescentes y adultos jóvenes refleja la relevancia del estudio para comprender patrones de comportamiento en etapas clave de desarrollo psicosocial.

- **Social media checking (Revisión de redes sociales):** Frecuencia con la que se revisan las redes sociales, con categorías que van desde 0 (nunca), 1 (no frecuente), 2 (seguido) hasta 3 (muy seguido). Esto no está en la literatura consultada pero se cree que es relevante.




Fig. 4.

La frecuencia con la que los usuarios revisan sus redes sociales se caracteriza por:

- **55 de los usuarios %:** Revisión **poco frecuente** (1-2 veces al día)
- **28 de los usuarios%:** **Nunca** revisan en lapsos específicos
- **13 de los usuarios%:** Revisión **a menudo** (varias veces por hora)
- **3 de los usuarios%:** Revisión **muy frecuente** (cada 10 minutos)

Estos datos revelan que, aunque la mayoría mantiene un uso esporádico, existe un segmento minoritario con patrones de revisión compulsiva, asociados a mayor riesgo de adicción conductual.

- **Sex (Sexo):** Indica el género del individuo, con valores binarios 1 (masculino) y 2 (femenino). Según Pellegrino, A., Stasi, A., & Bhatiasavi, V. (2022), ser mujer está asociado a un uso excesivo de redes sociales, por lo que se decidió añadir esta variable para verificar su relevancia.




Fig. 5. Distribución del Sexo de las personas.

La composición de la muestra presenta una predominancia femenina:

- **57.75% :** Mujeres
- **42.25%:** Hombres

3.2 Analisis bivariado entre predictoras y la dependiente BSMAS CUTOFF




Fig. 6. scatter plot bivariado.

En los gráficos de dispersión y distribuciones marginales para las variables *Sex*, *Time spent on social media*, *Social media checking* y *Age*, diferenciadas por la variable binaria *BSMAS_CUTOFF* (1: en riesgo de adicción a redes sociales, 0: sin riesgo).

Se observa una mayor densidad de de riesgo en las mujeres.

En "tiempo en redes sociales se observa que a partir de 4 a 6 horas a sesiones más largas en redes sociales aumenta la densidad de riesgo.

La densidad de riesgo se concentra incluso en personas que revisan poco sus redes sociales.

Parece que la densidad de riesgo se concentra en jóvenes entre 18 y 19 años.

Estos patrones respaldan la pertinencia de las variables seleccionadas como predictoras del riesgo de adicción a redes sociales, en línea con el objetivo de investigar su impacto en la percepción de satisfacción de vida en jóvenes.

4. Metodología

Dado que no se dispone de una variable directa para medir directamente el uso problemático de redes sociales (PSMU), se optó por utilizar la variable *BSMAS_CUTOFF*

(punto de corte de la Escala de Bergen de Adicción a las Redes Sociales) como proxy.

La elección de la proxy mencionada se fundamenta en la literatura existente, que asocia *BSMAS* con el uso problemático de redes sociales (PSMU) (Zarate et al., 2022), con una reducción del bienestar en personas de 18 a 35 años. Estudios como el de Hylkilä et al. (2024) demuestran que el PSMU afecta negativamente factores clave vinculados a la satisfacción vital, tales como, la calidad de las interacciones sociales, la capacidad para regular el estado de ánimo y la tendencia a realizar comparaciones sociales perjudiciales.

Modelo Bayesiano con BART

para modelar la probabilidad de presentar un comportamiento adictivo en redes sociales, se utilizó un modelo Bayesiano no paramétrico basado en Árboles Aditivos de Regresión Bayesianos (BART), adaptado para una variable dependiente binaria (*BSMAS_CUTOFF*). Este enfoque permite capturar relaciones no lineales y de alta complejidad entre las variables predictoras y la obojetivo.

Modelo Bayesiano BART para clasificación binaria

Sea $y_i \in \{0, 1\}$ la variable indicadora de adicción a redes sociales (*BSMAS_CUTOFF*) para el individuo i , y $\mathbf{x}_i$ el vector de predictores $\{Sex, Timespent, Checking, Loneliness, TOT_RSES\}$.

Estructura del modelo

$$\mu_i = \mu(\mathbf{x}_i) = \sum_{j=1}^m g_j(\mathbf{x}_i; T_j, M_j), \quad m = 50,$$

$$p_i = \sigma(\mu_i) = \frac{1}{1 + \exp(-\mu_i)},$$

$$y_i \sim \text{Bernoulli}(p_i).$$

Aquí:

- T_j es la estructura (particiones) del árbol j .
- M_j son los valores asignados a las hojas del árbol j .
- $g_j(\mathbf{x}_i; T_j, M_j)$ devuelve el valor de la hoja correspondiente en T_j para $\mathbf{x}_i$.
- $\sigma(\cdot)$ es la función sigmoide.

Priors

El prior de BART se define sobre la colección de m árboles para regular su complejidad:

- **Número de árboles:** $m = 50$.

- **Profundidad de los árboles (estructura T_j):**

$$P(\text{splitenprofundidad}) = \alpha(1+d)^{-\beta}.$$

Esto favorece árboles poco profundos y pocas particiones sucesivas.

- **Valores en las hojas (M_j):** Por defecto, PyMC3 no asigna un valor a priori para los valores de las hojas; en su lugar, en cada iteración del algoritmo de muestreo devuelve la media de los residuales

Verosimilitud

Dado el vector de probabilidades $\mathbf{p} = (\sigma(\mu_1), \dots, \sigma(\mu_n))$, la likelihood se expresa como

$$P(\mathbf{y} | \mu) = \prod_{i=1}^n [\sigma(\mu_i)]^{y_i} [1 - \sigma(\mu_i)]^{1-y_i}.$$

Este término Bernoulli es adecuado para la naturaleza binaria de la variable dependiente.

Implementación en PyMC

En PyMC se traduce directamente a:

Modelo Bayesiano BART para clasificación binaria

Sea $y_i \in \{0, 1\}$ la variable indicadora de adicción a redes sociales (BSMAS_CUTOFF) para el individuo i , y $\mathbf{x}_i$ el vector de predictores $\{Sex, Timespent, Checking, Loneliness, TOT_RSES\}$.

Estructura del modelo

$$\begin{aligned} \mu_i &= \mu(\mathbf{x}_i) = \sum_{j=1}^m g_j(\mathbf{x}_i; T_j, M_j), \quad m = 50, \\ p_i &= \sigma(\mu_i) = \frac{1}{1 + \exp(-\mu_i)}, \\ y_i &\sim \text{Bernoulli}(p_i). \end{aligned}$$

Aquí:

- T_j es la estructura (particiones) del árbol j .
- M_j son los valores asignados a las hojas del árbol j .
- $g_j(\mathbf{x}_i; T_j, M_j)$ devuelve el valor de la hoja correspondiente en T_j para $\mathbf{x}_i$.
- $\sigma(\cdot)$ es la función sigmoide.

Priors

El prior de BART se define sobre la colección de m árboles para regular su complejidad:

- **Número de árboles:** $m = 50$.
- **Profundidad de los árboles (estructura T_j):**

$$P(\text{splitenprofundidad}) = \alpha(1+d)^{-\beta}, \quad \alpha = 0.95, \beta = 2.$$

Esto favorece árboles poco profundos y pocas particiones sucesivas.

- **Valores en las hojas (M_j):** Cada parámetro de hoja tiene un prior

$$\mu_{leaf} \sim \mathcal{N}(0, \tau^2),$$

donde τ es ajustado automáticamente para controlar la varianza conjunta de $\sum_j g_j$.

Verosimilitud

Dado el vector de probabilidades $\mathbf{p} = (\sigma(\mu_1), \dots, \sigma(\mu_n))$, la likelihood se expresa como

$$P(\mathbf{y} | \mu) = \prod_{i=1}^n [\sigma(\mu_i)]^{y_i} [1 - \sigma(\mu_i)]^{1-y_i}.$$

Este término Bernoulli es adecuado para la naturaleza binaria de la variable dependiente.

Implementación en PyMC

En PyMC se traduce directamente a:

```
with pm.Model(coords={"n_obs": np.arange(n)})
as modelo_adiccion:
    = pmb.BART(
        "",
        X          = X.values,
        Y          = y.values,
        m          = 50,
        dims       = ["n_obs"]
    )
    p = pm.Deterministic(
        "p",
        pm.math.sigmoid(mu)
    )
    y_obs = pm.Bernoulli(
        "y_obs",
        p          = p,
        observed   = y.values
    )
```

```
idata = pm.sample(
    draws      = 2000,
    tune       = 1000,
    chains     = 3,
    random_seed = 123
)
pm.sample_posterior_predictive(
    idata,
    extend_inferencedata = True
)
```




Fig. 7. Esta figura muestra la estructura de árboles bayesianos utilizada, donde se puede observar los componentes usados para su construcción (likelihood, priors y posterior).

Algoritmo de muestreo MCMC

El modelo BART (Bayesian Additive Regression Trees) implementado en PyMC no puede utilizar métodos de muestreo basados en gradientes como Hamiltonian Monte Carlo (HMC) o su extensión No-U-Turn Sampler (NUTS), ya que el espacio de modelos definidos por árboles de decisión es discreto y no diferenciable.

En su lugar, BART emplea un muestreador MCMC diseñado específicamente para trabajar con árboles. El algoritmo opera de forma secuencial e iterativa: comienza ajustando un único árbol a los datos observados, y luego calcula los residuos (la diferencia entre las observaciones y

la predicción del árbol). A continuación, el segundo árbol se ajusta a esos residuos, y así sucesivamente.

Cada árbol en la secuencia contribuye parcialmente a la predicción final, y el proceso se repite hasta construir un conjunto de T árboles, donde cada uno corrige el error residual acumulado de los anteriores. Esta estrategia secuencial permite aproximar la distribución posterior de forma eficiente.

Esta implementación se basa en los desarrollos teóricos propuestos por Chipman et al. (2010) y adaptados al entorno computacional de PyMC (*PyMC Documentation - BART*, 2023).

Durante la estimación, se generaron 2,000 simulaciones con un tuning de 1000, aparte de 3 cadenas de markov y una semilla igual a 123.

5. Gráficos de convergencia




Fig. 8. Importancia de variable.

En este gráfico se muestra la importancia de las variables predictoras, ordenadas según su contribución a R^2 . Notar que el primer valor es el modelo con solo la variable "social media checking", el segundo valor es el modelo con la variable anterior y "time spent on social media" y así sucesivamente. En últimas aunque haya alta varianza, el modelo predice bien con las cuatro covariables predictoras




Fig. 9. Gráficos de dependencia parcial.

los PDP o gráficos de dependencia parcial muestran el efecto promedio de una variable predictora sobre la predicción del modelo, marginalizando (promediando) todas las demás variables. Es decir, podemos ver el efecto de la variable predictora sobre el valor predecido.

En este caso podemos ver en el primer gráfico de dependencia parcial que a mayor tiempo invertido en redes sociales aumenta su efecto sobre la categoría 1 (uso problemático de redes sociales). En el segundo gráfico podemos ver que una mayor edad tiene mas efecto sobre la adicción de redes sociales.




Fig. 10. Submodelos acumulativos.

Aquí se comparan las predicciones del modelo completo

(eje y, *ref model*) con las predicciones de submodelos que incluyen únicamente una de las covariables de interés (eje x). Cada punto naranja representa una observación, y la línea negra punteada indica la identidad perfecta ($y = x$), lo que sirve como referencia: cuanto más cercanas estén las predicciones del submodelo a esta línea, mayor es su concordancia con el modelo completo.




Fig. 11. predicción vs observados.

Probabilidades Globales por Categoría:			
	Categoría	Probabilidad	Porcentaje
0	PSMU	0.11144	11.14%
1	No PSMU	0.88856	88.86%

Se puede observar una buena relación entre los datos observados y los datos simulados, indicando que el modelo ajusta de manera adecuada.

Cálculo del porcentaje de aciertos

A partir de las muestras de la distribución predictiva posterior, podemos estimar el *accuracy* medio de la siguiente manera:

$$\text{accuracy_pct} = \frac{\text{np.mean}((\text{idata.posterior}_{\text{predictive}}[y_{\text{obs}}] - y_0) == 0) * 100}{1}$$

Lo cuál dio un resultado del 85%.

Resultados y Conclusiones

Respuesta a la pregunta de investigación y discusión de resultados

6. Resultados y Conclusiones

Basándonos en los gráficos de dependencia parcial y la predicción del modelo, podemos identificar las variables que mejor explican la adicción a las redes sociales en jóvenes de 14 a 22 años.

El modelo bayesiano de árboles aditivos de regresión (BART) utilizado en este estudio, que considera el sexo, el tiempo invertido en redes sociales, la frecuencia de revisión de redes sociales y la edad, demuestra ser un buen predictor de la adicción a las redes sociales, logrando una precisión del 85%.

6.1 Discusión acerca de los resultados

Los resultados de este estudio son coherentes con la literatura previa sobre el uso problemático de redes sociales. La frecuencia de revisión de redes sociales y el tiempo invertido en redes sociales muestran una clara asociación con la adicción. Los gráficos de dependencia parcial indican que, a mayor tiempo de uso diario y mayor frecuencia de revisión, mayor es la predicción de adicción. Esto subraya la importancia de los hábitos de uso en el desarrollo de comportamientos adictivos.

En cuanto al sexo, no pudimos observar si ser hombre o mujer es relevante a la adicción a redes sociales.

Respecto a la edad, los adolescentes mayores muestran una mayor tendencia a presentar riesgo de adicción. Este hallazgo es crucial, ya que esta etapa de desarrollo psicosocial es particularmente vulnerable a los impactos de las redes sociales.

La capacidad del modelo para detectar patrones de comportamiento y asociarlos con la adicción conductual se respalda con los datos reales analizados. La buena relación entre los datos observados y los datos simulados, con un *accuracy* del 85%, indica que el modelo ajusta de manera adecuada y es prometedor para identificar patrones de comportamiento relacionados con la adicción conductual en jóvenes.

Es importante considerar que, aunque el modelo muestra un buen ajuste, se debe tener precaución con posibles sobreajustes en futuras investigaciones.

7. Referencias

- Andreassen, C. S., Pallesen, S., & Griffiths, M. D. (2017). The relationship between addictive use of social media, narcissism, and self-esteem: Findings from a large national survey. *Addictive Behaviors*, *64*, 287–293. <https://doi.org/10.1016/j.addbeh.2016.03.006>
- American Academy of Pediatrics. (2011). Supporting the health care transition from adolescence to adulthood in the medical home. *Pediatrics*, *128*(1), 182–200. <https://doi.org/10.1542/peds.2018-2587>
- Blease, C. R. (2015). Too many “friends”, too few “likes”? Evolutionary psychology and Facebook depression. *Review of General Psychology*, *19*(1), 1–13. <https://doi.org/10.1037/gpr0000030>
- Brown, I. (1997). A theoretical model of the behavioural addictions—Applied to offending. In J. E. Hodge, M. McMurran, & C. R. Hollins (Eds.), *Addicted to crime?* (pp. 13–65). John Wiley.
- Buote, V. M., Wood, E., & Pratt, M. (2009). Exploring similarities and differences between online and offline friendships: The role of attachment style. *Computers in Human Behavior*, *25*(2), 560–567. <https://doi.org/10.1016/j.chb.2008.12.022>
- Casale, S., & Banchi, V. (2020). Narcissism and problematic social media use: A systematic literature review. *Addictive Behaviors Reports*, *11*, 100252. <https://doi.org/10.1016/j.abrep.2020.100252>
- Cheng, C., Lau, Y.-C., Chan, L., & Luk, J. W. (2021). Prevalence of social media addiction across 32 nations: Meta-analysis with subgroup analysis of classification schemes and cultural values. *Addictive Behaviors*, *117*, 106845. <https://doi.org/10.1016/j.addbeh.2021.106845>
- Duradoni, M., Innocenti, F., & Guazzini, A. (2020). Well-being and social media: A systematic review of Bergen addiction scales. *Frontiers in Future Internet*, *2*, 24. <https://doi.org/10.3389/ffinternet.2020.00024>
- Elphinston, R. A., & Noller, P. (2011). Time to face it! Facebook intrusion and the implications for romantic jealousy and relationship satisfaction. *Cyberpsychology, Behavior, and Social Networking*, *14*(11), 631–635. <https://doi.org/10.1089/cyber.2010.0318>
- Griffiths, M. D. (2005). En “komponenter” modell for avhengighet innenfor en biopsykosial ramme. *Journal of Substance Use*, *10*(4), 191–197. <https://doi.org/10.1080/14659890500114359>
- Hylkilä, K., Männikkö, N., Castrén, S., Mustonen, T., Peltonen, A., Konttila, J., Männistö, M., & Kääriäinen, M.

(2024). Association between problematic social networking site use and social well-being among young adults: A systematic review. *Journal of Affective Disorders Reports*, 16, 100775. <https://doi.org/10.1016/j.jadr.2024.100775>

Andreassen, C. S., Billieux, J., Griffiths, M. D., Kuss, D. J., Demetrovics, Z., Mazzoni, E., & Pallesen, S. (2016). The relationship between addictive use of social media and video games and symptoms of psychiatric disorders: A large-scale cross-sectional study. *Psychology of Addictive Behaviors*, 30(2), 252–262. <https://doi.org/10.1037/adb0000160>

Inchley, J. C., Stevens, G. W. J. M., Samdal, O., & Currie, D. B. (2020). Enhancing understanding of adolescent health and well-being: The health behaviour in school-aged children study. *Journal of Adolescent Health*, 66(6), S3–S5. <https://doi.org/10.1016/j.jadohealth.2020.03.014>

Montag, C., Yang, H., & Elhai, J. D. (2021). On the psychology of TikTok use: A first glimpse from empirical findings. *Frontiers in Public Health*, 9, 641673. <https://doi.org/10.3389/fpubh.2021.641673>

Ozimek, P., Brailovskaia, J., & Bierhoff, H.-W. (2023). Active and passive behavior in social media: Validating the Social Media Activity Questionnaire (SMAQ). *Telematics and Informatics Reports*, 10, 100048. <https://doi.org/10.1016/j.teler.2023.100048>

Pellegrino, A., Stasi, A., & Bhatiazevi, V. (2022). Research trends in social media addiction and problematic social media use: A bibliometric analysis. *Frontiers in Psychiatry*, 13, 1017506. <https://doi.org/10.3389/fpsyt.2022.1017506>

Statista. (2024). Number of social media users worldwide from 2017 to 2028 (in billions). <https://www.statista.com/statistics/278414/number-of-worldwide-social-network-users/>

Vannucci, A., & McCauley Ohannessian, C. (2019). Social media use subgroups differentially predict psychosocial well-being during early adolescence. *Journal of Youth and Adolescence*, 48(8), 1469–1493. <https://doi.org/10.1007/s10964-019-01060-9>

We Are Social. (2022). *Digital 2022: Global Overview Report*. <https://datareportal.com/reports/digital-2022-global-overview-report>

Zarate, D., Hobson, B. A., March, E., Griffiths, M. D., Stavropoulos, V. (2023). Psychometric properties of the Bergen Social Media Addiction Scale: An analysis using item response theory. *Addictive Behaviors Reports*, 17, 100473. <https://doi.org/10.1016/j.abrep.2022.100473>